

Einführung in die Datenbanken

Felix Leitl

23. Juli 2024

Inhaltsverzeichnis

Grundlagen	5
Modellierung	5
Warum Datenbanken	5
Vorteile einer Datenbank	5
Nachteile	5
Begriffe	6
Datenbank	6
Datenbank-Management-System	6
Datenbanksystem	6
Datenbankanwendung	6
Datenmodell	6
Datenbankschema	6
Nutzdaten	6
Metadaten	6
Konzeptionelles Schema	6
Externes Schema	7
Internes Schema	7
Phasen des Datenbankentwurfs	7
ERM	7
Relationenmodell	7
Bestandteile eines Datenmodells	7
Begriffe	7
Erweiterte Attributdefinition	8
Sicherstellung der Referenziellen Integrität	8
Löschen eines referenzierten Primärschlüssels	8
Ändern eines referenzierten Primärschlüssels	8
Integritätsbedingungen	8
„System-enforced Integrity“	8
Benutzerdefinierte oder „globale“ Integritätsbedingung	9

Mapping	9
Abbildungskonzepte	9
Algorithmus	9
Reguläre Entity-Typen	9
Schwache Entity-Typen	9
M:N-Beziehungen	9
N:1-Beziehungen	10
1:1-Beziehungen	10
Mehrwertige Attribute	10
Mehrstellige Beziehungen	10
Generalisierung/Spezialisierung	10
Kategorien	10
Normalisierung	10
Anomalien	10
Funktionale Abhängigkeit $X \rightarrow Y$	11
Volle Funktionale Abhängigkeit	11
Normalformen	11
Erst Normalform (1NF)	11
Zweite Normalform (2NF)	11
Dritte Normalform (3NF)	11
Boyce-Codd-Normalform (BCNF)	11
Vierte Normalform (4NF)	11
Denormalisierung	11
Wann ist eine Denormalisierung angebracht?	11
Relationenalgebra	12
SQL	12
Grundstruktur	12
Neue Spalten	12
Duplikate	12
IN	12
EXISTS	13
Mengenvergleiche und Quantoren	13
Join	13
FROM-Klausel	13
Auto-Join und Alias-Namen	13
Cross Join	13
Θ -Join	13
Gleichverbund	13
Natürlicher Verbund	14
Äußerer Verbund	14
Sortierung	14
Mengenoperationen	14
AVG	14
COUNT	14
SUM	14
GROUP BY	14

HAVING	14
Abarbeitung	15
NULL	15
CASE	15
WITH	15
Änderungen in SQL	15
Einfügen	15
Löschen	16
Update	16
Integritätsbedingungen	16
VIEW	17
Zugangskontrolle	17
Alter Table	17
Multidimensionale Datenmodellierung	17
OLTP vs. OLAP	17
OLTP	17
OLAP	17
Relationenmodell vs. Multidimensionales Datenmodell	17
Relationenmodell	17
Multidimensionales Datenmodell	18
Charakterisierung der Datenanalyse	18
Mikro-, Makro- und Meta-Daten	18
Anforderungen	18
MD Entwurf	19
Logisches Schema einer Dimension	19
Instanz einer Dimension	19
Schema eines Datenwürfels	19
Instanz eines Würfels	20
Multidimensionale Operatoren	20
Aggregation	20
MD Schemaentwurf (Kimball)	21
ROLAP	21
Star Schema	21
Snowflake Schema	21
Schichtenmodell	21
Konsequenzen	21
Schichtenmodell eines DBVS	22
Erweitertes Schichtenmodell	24
Satzadresse	24
Transaktionen	25
Erwünschte Zustände auf einer Platte	25
Physische Konsistenz	25
Logische Konsistenz	25
Annahmen	25
Nach einem Fehler	25
Systemunterstützung	25

Der herzustellende konsistente Zustand kann sein	25
Voraussetzungen	25
Pufferverwaltung	26

Grundlagen

Modellierung

Ein Modell ist ein zweckgerichtetes Abbild der Wirklichkeit

Zweck:

- Spezifizieren
- Konstruieren
- Visualisieren
- Dokumentieren

Warum Datenbanken

- Große Software-Systeme
- Viele Anwendungen/Benutzer arbeiten mit den gleichen Daten
- Daten sollen auch nach Ende eines Programms verfügbar bleiben
- Daten sollen vor Verlust geschützt werden
- Daten sollen konsistent bleiben

Vorteile einer Datenbank

- Anwendungsneutralität
- Vermeidung redundanter Daten
- Zentrale Kontrolle der Datenintegrität
- Synchronisation im Mehrnutzerbetrieb
- Fehlertoleranz
- Performance
- Skalierbarkeit
- Verkürzte Entwicklungszeiten für Anwendungen
- Umsetzung von Standards

Nachteile

- Hohe initiale Kosten
- General purpose software
- Signifikanter Overhead

Begriffe

Datenbank

Eine Datenbank ist eine Sammlung zusammenhängender Daten.

- repräsentiert einen Ausschnitt der realen Welt (Miniwelt)
- Logisch kohärente Sammlung von Daten
- Hat definierten Zweck

Datenbank-Management-System

Sammlung von Programmen zur Verwaltung einer Datenbank

- Erzeugung von DB
- Wartung von DB
- Konsistenter Zugriff auf DB

Datenbanksystem

- DB + DBMS

Datenbankanwendung

- DBS + Anwendungsprogramme

Datenmodell

- Strukturierungsvorschrift für Daten (z.B. Tabellenform)

Datenbankschema

- Beschreibung einer konkreten Datenbank

Nutzdaten

- Eigentliche Datenbank

Metadaten

- Struktur der DB
- Information über Speicherungsstrukturen

Konzeptionelles Schema

- Beschreibt sämtliche Daten auf logischer Ebene
- z.B. Patient (NR. Krankenkasse, Laborwerte)

Externes Schema

- Beschreibt den für die Anwendung relevanten Teil einer DB auf logischer Ebene
- z.B. für den Arzt: `Patient (Nr., Laborwerte)` und für die Verwaltung: `Patient (Nr., Krankenkasse)`

Internes Schema

- Beschreibt die interne Speicherungsstrukturen einer Datenbank
- Unsichtbar für Anwendung
- z.B. Index über Attribut `Nr.` von `Patient`

Phasen des Datenbankentwurfs

- Konzeptioneller Entwurf
 - Abbildung auf Semantisches Datenmodell (z.B. E/R-Modell)
- Logischer Entwurf
 - Abbildung auf Datenmodell

ERM

Siehe Vorlesungsfolien

Relationenmodell

Bestandteile eines Datenmodells

- einfache Datentypen und Konstruktoren für zusammengesetzte Datentypen
- Konsistenzregeln:
 - inhärente Konsistenzregeln:
gelten für ein Datenmodell per Konvention
 - explizite Konsistenzregeln:
werden für eine Anwendung im Zuge der Datendefinition festgelegt
- Benennungskonvention für die Bezeichnung von Datenbankelementen

Begriffe

- Relation: Menge von gleichartig aufgebauten Tupeln
- Tupel: Zeile einer Tabelle
- Kardinalität: Anzahl der Tupel in einer Relation
- Attribut: Spalte einer Tabelle

- Grad: Anzahl der Attribute
- Relationenschema:
 - Beschreibung einer Relation
 - besteht aus Relationennamen (z.B. **Personen**)
 - und einer Menge von Attributen (z.B. {PNr, Vorname, Nachname})
 - Jedes Attribut wird definiert über einen Attributnamen und einen Wertebereich
 - z.B. **Personen** (PRn, Vorname, Nachname)
- Relationales Datenbankschema: Menge von Relationaldatenbankschemata
- Wertebereich: zulässige Attribute
- Superschlüssel: definiert ein Tupel eindeutig
- Schlüsselkandidat: Minimaler Superschlüssel
- Primärschlüssel: Ausgewählter Schlüsselkandidat
- Fremdschlüssel: Attribut, dass mit Primärschlüssel einer Tabelle auf ein bestimmtes Tupel verweist

Erweiterte Attributdefinition

- NOT NULL
- UNIQUE
- PRIMARY KEY

Sicherstellung der Referenziellen Integrität

Löschen eines referenzierten Primärschlüssels

- RESTRICTED: ablehnen der Operation
- CASCADES: Alle referenzierenden Tupel werden auch gelöscht
- NULLIFIE: Referenzen werden auf NULL gesetzt
- SET DEFAULT

Ändern eines referenzierten Primärschlüssels

- RESTRICTED
- CASCADES

Integritätsbedingungen

„System-enforced Integrity“

- Primärschlüsseleigenschaft
- Referenzielle Integrität

Benutzerdefinierte oder „globale“ Integritätsbedingung

- Bedingungen aus der Anwendungsdomäne, die explizit formuliert werden müssen
- Kontrolliert durch das DBMS
- Operationen, die die Integritätsbedingungen verletzen werden abgelehnt

Mapping

Abbildungskonzepte

ER-Modell	Relationenmodell
Entity-Typ	„Entity“-Relation
1:1- oder 1:N-Beziehungstyp	Fremdschlüssel oder
M:N-Beziehungstyp	Beziehungstabelle mit 2 FS
N-ärer Beziehungstyp	Beziehungstabelle mit N FS
Einfaches Attribut	Attribut
Zusammengesetztes Attribut	Menge von Attributen
Mehrwertiges Attribut	„Attribut“-Relation mit FS
Wertebereich	Wertebereich
Schlüsselattribut	Schlüsselkandidat → Primärschlüssel

Algorithmus

Reguläre Entity-Typen

- Erzeuge eine Relation R, die alle einfachen Attribute von E umfasst
 - Bei zusammengesetzten Attributen nur Komponenten als eigenständige Attribute
- Wähle aus Schlüsselkandidaten einen Primärschlüssel
 - zusammengesetzt → Komponenten bilden zusammen den Primärschlüssel
 - Jeder Schlüsselkandidat, außer PS wird UNIQUE & NOT NULL

Schwache Entity-Typen

- Erzeuge eine Relation, die alle einfachen Attribute von W umfasst
- Füge als Fremdschlüssel alle PS-Attribute der Owner-Typen ein
- PS wird Kombination aller FSA, zusammen mit partiellem Schlüssel (falls vorhanden)

M:N-Beziehungen

- Erzeuge Relation die alle einfachen Attribute von X umfasst
- FS → PSA der beidem Relationen
- PS ist Kombination der FSA

N:1-Beziehungen

- identifiziere die Relation, die dem Entity-Typ E auf der N-Seite des Beziehungstyps entspricht
- Füge den PS des anderen ET als FS in R ein
- Füge alle einfachen Attribute des Beziehungstyps X als Attribute in R ein

1:1-Beziehungen

- Identifiziere Relationen R & S
- Nehme den PS von S bzw. R als FS von R bzw. S auf UNIQUE
- Füge alle einfachen Attribute in R bzw. S ein

Mehrwertige Attribute

- Erzeuge Relation R mit folgenden Attributen:
 - Ein Attribut A, dass dem abzubildenden Attribut A entspricht
 - Den PS K der Relation S, die zu E gehört, als FS auf S
- Der PS der Relation R ist die Kombination von A & K

Mehrstellige Beziehungen

- Erzeuge Relation R, die alle einfachen Attribute von B umfasst
- $FS \rightarrow PS$ aller Relationen
- $PS \rightarrow$ Kombination aller FS

Generalisierung/Spezialisierung

siehe VL

Kategorien

siehe VL

Normalisierung

Anomalien

- Einfüge-Anomalie (ohne hinzufügen von Info B, geht Info A nicht)
- Lösch-Anomalie
- Änderungs-Anomaile

Funktionale Abhängigkeit $X \rightarrow Y$

Y ist funktional abhängig von X , wenn es keine Tupel geben darf, in denen für gleiche X -Werte verschiedene Y -Werte auftreten

Linke Seite der FA wird „Determinante“ genannt

Volle Funktionale Abhängigkeit

Y ist voll funktional abhängig von X , wenn es keine echte Teilmenge $Z \subset X$ gibt, für die gilt $Z \rightarrow Y$

Normalformen

Erst Normalform (1NF)

Eine Relation, die nur atomare Attributwerte besitzt (keine Mengen als Attributwert)

Zweite Normalform (2NF)

Eine Relation, in 1NF & deren Nicht-Schlüsselattribute voll funktional von jedem Schlüsselkandidaten abhängen

Dritte Normalform (3NF)

Eine Relation, deren Nicht-Schlüsselkandidaten nicht transitiv abhängig von einem Schlüsselkandidaten sind

Boyce-Codd-Normalform (BCNF)

Eine Relation, bei welcher jede Determinante einer FA ein Superschlüssel ist

Vierte Normalform (4NF)

Eine Relation R ist in 4NF, wenn für jede nicht-triviale mehrwertige Abhängigkeit $X \twoheadrightarrow A \in R$ gilt: X ist Superschlüssel von R

Eine mehrwerte Abhängigkeit gilt, wenn die Attributwerte von C nur von A und nicht von B abhängig sind

$A \twoheadrightarrow C$ ist trivial, wenn $C \in A$ oder $B = \emptyset$

Denormalisierung

Normalisierung kostet Zugriffszeit

Wann ist eine Denormalisierung angebracht?

- Seltene Änderungen
- Viele Joins

Bei weiteren Fragen Anhang VL_06 lesen

Relationenalgebra

SQL

Grundstruktur

```
SELECT Personalnummer, Name
FROM Mitarbeiter
WHERE Name = 'Müller'
[GROUP BY]
[HAVING]
ORDER BY Geburtsdatum DESC;
```

Neue Spalten

```
SELECT MNR, Gehalt * 1.1 AS Gehaltsprognose
FROM Angestellte;
```

```
SELECT MNR, Gehalt + Werbeeinnahmen AS Einkünfte
FROM Angestellte;
```

```
(
    SELECT Name, Vorname, Gehalt
    FROM Angestellte)
UNION
(
    SELECT Name, Vorname, NULL AS Gehalt
    FROM Kunde);
```

Duplikate

```
SELECT DISTINCT Wohnort
FROM Angestellte;
```

IN

```
SELECT *
FROM Angestellte
WHERE AbtNr IN (6, 4, 2);
```

```
SELECT Nachname
FROM Angestellte
WHERE AbtNr IN
(
    SELECT AbtNr
    FROM Abteilungen
    WHERE Ort = 'Erlangen'
);
```

EXISTS

```
SELECT *  
FROM Angestellte  
WHERE EXISTS (SELECT * FROM Abteilungen WHERE Ort = 'Erlangen');
```

Inner Anfrage muss Bezug zur äußeren Anfrage haben

Mengenvergleiche und Quantoren

```
SELECT *  
FROM Angestellte  
WHERE Wohnort = ANY (SELECT Ort FROM Abteilungen);
```

```
SELECT *  
FROM Angestellte  
WHERE Gehalt >= ALL (SELECT Gehalt FROM Angestellte);
```

Join

FROM-Klausel

```
SELECT PersNr, Wohnort, Bezeichnung  
FROM Angestellte, Abteilung  
WHERE Angestellte.AbtNr = Abteilung.AbtNr  
      AND Gehalt > 30000  
      AND Ort = 'Nürnberg';
```

Auto-Join und Alias-Namen

```
SELECT m.Nachname AS Mitarbeiter, v. Nachname AS Chef  
FROM Angestellte [AS] m, Angestellte [AS] v  
WHERE m.VorgesNr = v.PersNr  
AND m.Gehalt > v.gehalt;
```

Cross Join

```
SELECT * FROM Angestellte, Abteilung;  
SELECT * FROM Angestellte CROSS JOIN Abteilung
```

⊖-Join

```
SELECT * FROM Angestellte, Abteilungen  
WHERE Angestellte.AbtNr = Abteilungen.AbtNr;  
SELECT * FROM Angestellte JOIN Abteilungen ON Angestellte.AbtNr = Abteilung.AbtNr;
```

Gleichverbund

```
SELECT * FROM Angestellte JOIN Abteilung USING (AbtNr);
```

Natürlicher Verbund

```
SELECT * FROM Angestellte NATURAL JOIN Abteilungen;
```

Äußerer Verbund

```
SELECT * FROM Linke NATURAL LEFT OUTER JOIN Rechte;  
SELECT * FROM Linke LEFT JOIN Rechte USING (B);
```

```
SELECT * FROM Linke RIGHT JOIN Rechte;
```

```
SELECT * FROM Linke NATURAL FULL OUTER JOIN Rechte;
```

Sortierung

```
SELECT * FROM Angestellte  
WHERE AbtNr = 5  
ORDER BY Gehalt ASC, Nachname DESC;
```

Mengenoperationen

AVG

```
SELECT AVG(Gehalt) FROM Angestellte WHERE AbtNr = 505;
```

COUNT

```
SELECT COUNT(DISTINCT Nachname) FROM Angestellte;  
SELECT COUNT(*) FROM Angestellte;
```

SUM

```
SELECT SUM(Gehalt) FROM Angestellte;
```

GROUP BY

Nötig, wenn man Aggregationen auf Teilmengen durchführt

```
SELECT AbtNr, AVG(Gehalt)  
FROM Angestellte  
GROUP BY AbtNr
```

HAVING

Einschränkungen nach der Gruppenbildung

```
SELECT AbtNr, SUM(Gehalt)  
FROM Angestellte  
GROUP BY AbtNr  
HAVING MAX(Gehalt) > 100000 OR MIN(Gehalt) < 20000;
```

Abarbeitung

1. FROM
2. WHERE
3. GROUP BY
4. HAVING
5. SELECT
6. ORDER BY

NULL

```
SELECT Name
FROM Mitarbeiter
WHERE Gehalt ISNULL
```

CASE

```
SELECT PerNr, Name,
CASE
    WHEN Gehalt > 100000 THEN 'Grossverdiener'
    WHEN Quantity > 30000 THEN 'Normalo'
    WHEN Gehalt ISNULL THEN 'unbekannt'
    ELSE 'ARM'
END AS Gehaltsklasse
FROM Angestellte;
```

WITH

```
WITH D AS (SELECT AVG(x.Gehalt) AS Durchschnitt FROM Angestellte x)
SELECT m.Nachname, m.Nachname
FROM Angestellte
WHERE Gehalt > (SELECT Durchschnitt FROM D);
```

Änderungen in SQL

Einfügen

```
INSERT INTO Angestellte (PersNr, Nachname, AbtNr)
VALUES (1467, 'Seiler', 505);
```

```
CREATE TABLE Spitzenverdiener (
    PersNr          INTEGER not null,
    Nachname        VARCHAR(30),
    Gehalt          INTEGER
);
INSERT INTO Spitzenverdiener
(
    SELECT PersNr, Nachname, Gehalt
```

```

FROM Angestellte
WHERE Gehalt > 100000 );

```

Löschen

```

DELETE FROM Angestellte
WHERE PerNr = 704;

```

```

DELETE FROM Angestellte
WHERE AbtNr IN (
    SELECT AbtNr
    FROM Abteilungen
    WHERE Ort = 'Trotzdorf'
);

```

Update

```

UPDATE Angestellte SET AbtNr = 501
WHERE AbtNr >= 502 AND AbtNr <= 505 AND Gehalt > 60000;

```

```

UPDATE Angestellte SET Gehalt = Gehalt * 1.1
WHERE AbtNr IN (
    SELECT AbtNr
    FROM Abteilungen
    WHERE Ort = 'Nürnberg'
)

```

Integritätsbedingungen

```

CREATE TABLE Angestellte (
    PersNr          INT,
    Vorname         VARCHAR(20),
    Name            VARCHAR(30),
    AbtNr           INT NOT NULL DEFAULT 1,
    VorgesNr        INT,
    CONSTRAINT      MitarbeiterPK
        PRIMARY KEY (PersNr),
    CONSTRAINT      VorgesetzterFK
        FOREIGN KEY (VorgesNr) REFERENCES Angestellte (PersNr)
            ON DELETE SET NULL
            ON UPDATE CASCADE,
    CONSTRAINT      AbteilungFK
        FOREIGN KEY (AbtNr) REFERENCES Abteilungen (AbtNr)
            ON DELETE SET DEFAULT
            ON UPDATE CASCADE,
);

```


VIEW

```
CREATE VIEW Arme-Angestellte (PerNr, Nachname, Lohn) AS
    SELECT PersNr, Nachname, Gehalt AS Lohn
    FROM Angestellte
    WHERE Gehalt < 400000;
```

```
SELECT AVG(Lohn)
FROM Arme-Angestellte;
```

Zugangskontrolle

```
GRANT SELECT (PersNr, Nachname, Gehalt), UPDATE (Gehalt)
ON Angestellte TO Schmidt;
```

```
REVOKE UPDATE (Gehalt)
ON Angestellte FROM Schmidt
```

Alter Table

```
ALTER TABLE flaeche
ADD COLUMN anteilSportFreizeit REAL CHECK (anteilSportFreizeit >= 0 AND anteilSportFreizeit <= 100);
```

```
ALTER TABLE flaeche
ADD COLUMN anteilWald REAL CHECK (anteilWald >= 0 AND anteilWald <= 100);
```

Multidimensionale Datenmodellierung

OLTP vs. OLAP

OLTP

Online Transaction Processing

OLAP

Online Analytical Processing

Relationenmodell vs. Multidimensionales Datenmodell

Relationenmodell

- Einfach, wenige Modellierungskonstrukte
- Anwendungsneutral
- Keine „eingebaute“ Anwendungssemantik

⇒ Nützlich in beliebigen Domänen, manchmal etwas komplizierter in der Anwendung

Multidimensionales Datenmodell

- Komplexer, mehr Modellierungskonstrukte
- Speziell auf Anwendung zur Datenanalyse zugeschnitten

⇒ Nur nützlich für analytische Zwecke

Charakterisierung der Datenanalyse

- Qualifizierende und Quantifizierende Daten
 - Spezielle funktionale Abhängigkeiten ⇒ spezifische Repräsentation
- Klassifikationshierarchien
 - Aggregierende Anfragen nutzen Hierarchien zu ihrem Vorteil
- Stabile Daten
 - Daten werden (fast) nie geändert
 - Nur neue Daten hinzugefügt
- Zugriff auf materialisierte Sichten
 - Voraggregierte Daten

Mikro-, Makro- und Meta-Daten

- Mikro-Daten
 - Einzelne Observationen, beschreiben Elementarereignisse
 - Ergebnis der Ladephase → Basisdaten
- Makro-Daten
 - Aggregierte Daten für die Datenanalyse
 - Ergebnis der Auswertungsphase → Data Warehouse, Data Mart
- Meta-Daten
 - Beschreibungsdaten
 - Beschreiben die Eigenschaften von Mikro-Daten und Makro-Daten
 - Beschreiben auch den Entstehungsprozess

Anforderungen

- Datenwürfel soll flexibel durchsucht werden können
- Qualifizierende Daten → Dimensionen des Würfels
- Quantifizierende Daten → Fakten (Zellen des Würfels)
- Dimensionen müssen unabhängig sein
- Eindeutige Trennung von Fakten

MD Entwurf

1. Benutzer-Anforderungen
2. Konzeptionelle Schema
 - semi-formal: mE/R, mUML
3. Logisches Schema
 - formal: Dimensionen, Cubes
4. Physisches Schema
 - Relationen, MD-Strukturen

Logisches Schema einer Dimension

- Partiiell geordnete Menge D von Klassifikationsstufen
- Partielle Ordnung erlaubt parallele Hierarchie: „Pfade“
- Orthogonalität: Verschiedene Dimensionen sind unabhängig

Instanz einer Dimension

- Funktionale Abhängigkeiten \rightarrow Baumstruktur auf Instanzebene
- Jeder Pfad im Schema einer Dimension definiert eine Klassenhierarchie
- Klassenhierarchie ist ein balancierter Baum
- Instanz einer Dimension ist die Menge aller Klassenhierarchien

Schema eines Datenwürfels

- Definition: Schema eines Datenwürfels C
 - Struktur: $C[G, M]$
 - Menge von Fakten: $M = (M_1, \dots, M_m)$
 - Granularität: $G = (G_1, \dots, G_n)$
 - Jedes G_i ist ein dimensionales Attribut
- Bsp.:
 - Sales und Turnover pro Article, Shop und Day
 - * $C_{\text{sales}}[(P.\text{Article}, S.\text{Shop}, T.\text{Day}), (\text{Sales}, \text{Turnover})]$
- Fakten (Kenngrößen)
 - können auch Eigenschaften zugesprochen werden
 - sind aber keine Datenstruktur an sich, eher analog zu einem Wertebereich
- Aggregatstyp

- nicht-triviale Eigenschaften neben Name und Wertebereich → definiert, welche Aggregationsoperationen auf einer Kenngröße ausgeführt werden dürfen
 1. beliebig aggregierbar (Sales, Turnover, ...): FLOW
 2. nicht temporal summierbar (Stock, Inventory, ...): STOCK
 3. nicht summierbar (Preis, Steuer, i.Allg. Faktoren): VPU (Value per Unit)
- MIN, MAX & AVG können immer durchgeführt werden

Instanz eines Würfels

- Alle Zellen aus dem Definitionsbereich des Datenwürfels werden als existierend angenommen, egal ob ein Datensatz physisch vorhanden ist
- Gegenüberstellung: Im relationalen Datenmodell herrscht eine andere Grundannahme vor (→ „closed world“-Prinzip): Nichts wird angenommen, was nicht explizit als Datensatz vorhanden ist (→ „Intension vs. Extension“)

Multidimensionale Operatoren

- Slice
- Dice
- Drill-Down: Abstieg in der Klassifikationshierarchie zu feinerem Granulat
- Roll-Up: Aufstieg in der Klassifikationshierarchie hin zu größerem Granulat
- Drill-Across: Verknüpfung mehrerer Datenwürfel mit gemeinsamen Dimensionen
- Drill-Through: Wechsel zu den Originaldaten
- Pivottisierung: Wechsel der Darstellung in einer Pivottabelle, entspricht Drehen des Würfels

Aggregation

- Zusammenfassen mehrerer Zellen
- Notwendig beim Roll-Up
- Bsp.: vom Tag zum Monat, vom Produkt zur Kategorie
- Standard
 - SUM
 - AVG
 - MIN
 - MAX
 - COUNT
- Ordnungsbasiert
 - cumulating
 - ranking

MD Schemaentwurf (Kimball)

1. Auswahl eines Geschäftsprozesses → Subjektorientierung
2. Auswahl der Erfassungsgranularität
3. Auswahl der Dimensionen
4. Auswahl der Kennziffern

ROLAP

- Idee für die Speicherung multidimensionaler Daten
 - Tabelle mit zusammengesetztem Primärschlüssel aus den Dimensionen
 - (Nur) für jede vorhandene Datenzeile wird ein Tupel abgespeichert
- Trennung von Struktur und Inhalt führt zur Aufteilung in
 - zentrale „Fact Table“ und
 - Dimensionstabellen

Star Schema

- Eine Tabelle für jede Dimension

Snowflake Schema

- Normalisierung der Dimensionstabellen
- Viele Tabellen je Dimension

Schichtenmodell

Konsequenzen

- Höhere Ebenen werden einfacher
- Änderungen auf höheren Ebenen haben keinen Einfluss auf niedrigere
- Änderungen sind unproblematisch, solange die Schnittstelle gleich bleibt
- Ebenen sind wiederverwendbar
- Tiefere Ebenen können vor höheren getestet werden

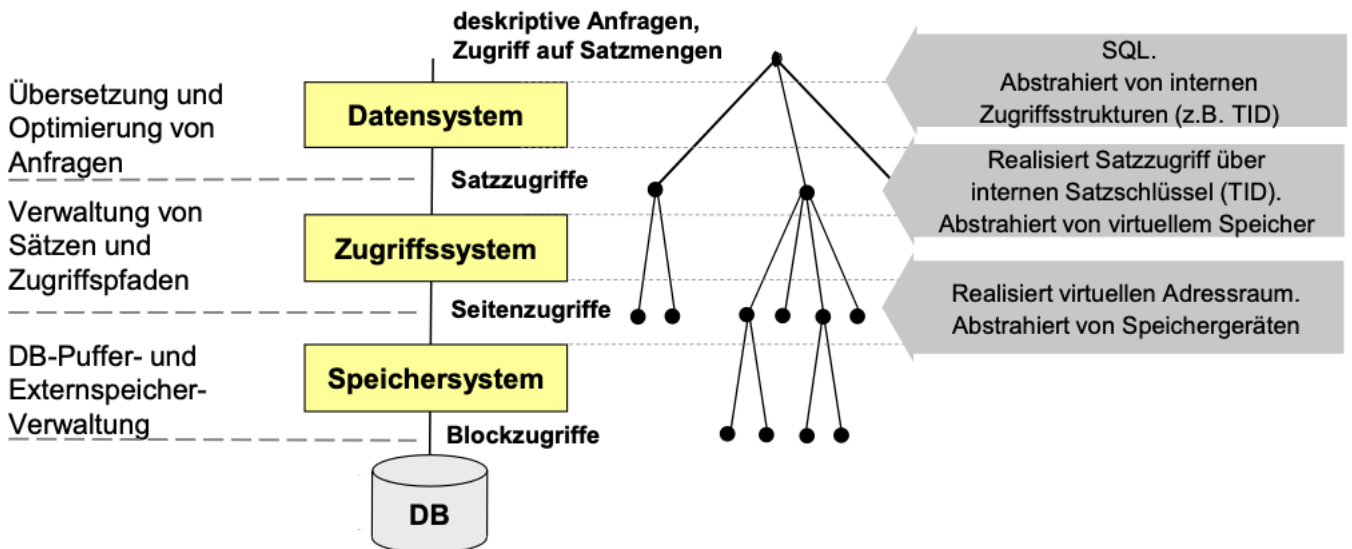
⇒

- Reduzierte Komplexität
- Verbesserung der Wartbarkeit
- Verbesserung der Portierbarkeit
- Verbesserung der Wiederverwendbarkeit

Schichtenmodell eines DBVS

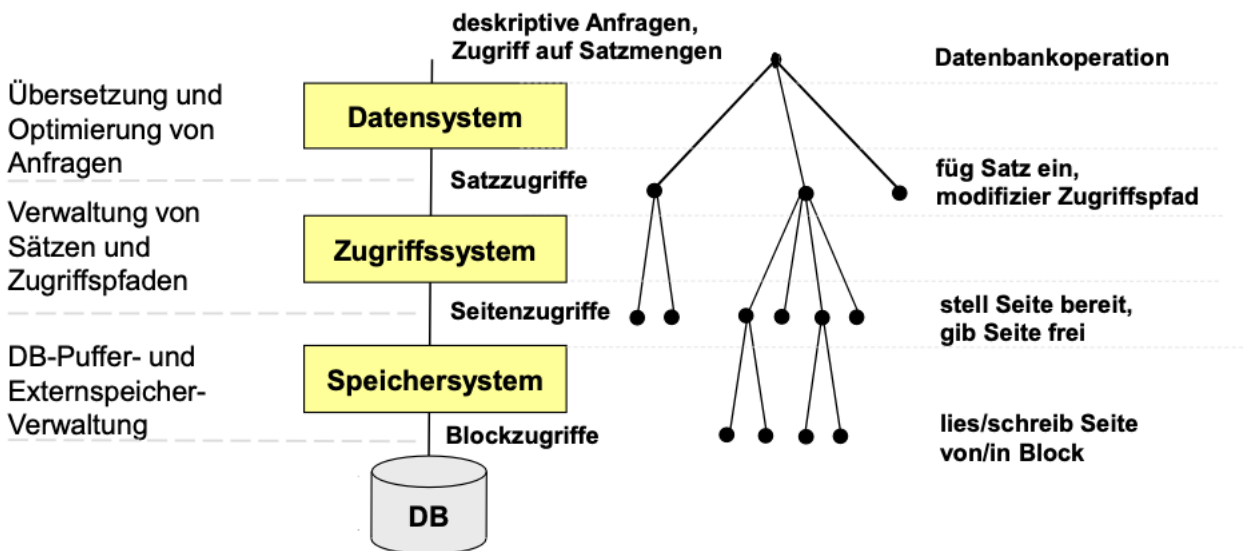
Aufgaben der Schicht

Abstraktionen der Schnittstelle




Aufgaben der Schicht


Operationen an der Schnittstelle



Aufgaben der Schicht



Erweitertes Schichtenmodell



Satzadresse

Eine Satzadresse sollte

- eindeutig

- unveränderlich
- Paar aus Seitennummer und Feldindex

sein

Transaktionen

Erwünschte Zustände auf einer Platte

Physische Konsistenz

- Korrektheit der Speicherkonstrukte
- Alle Verweise und Adressen (TIDs) stimmen
- Alle Indexe sind vollständig und stimmen mit Primärdaten überein

Logische Konsistenz

- Korrektheit der Dateninhalte
- Alle im Datenbankschema formulierten Integritätsbedingungen sind erfüllt

Annahmen

- Alle vollständig ausgeführten DB-Operationen hinterlassen einen physisch konsistenten Zustand
- Alle vollständig ausgeführten Anwendungsprogramme hinterlassen einen logisch konsistenten Zustand

Nach einem Fehler

- Die Daten sind i.Allg. weder physisch noch logisch konsistent

Systemunterstützung

- zur Wiederherstellung eines logischen und physischen konsistenten Zustands der Daten nach einem Fehlerfall

Der herzustellende konsistente Zustand kann sein

- Vor Beginn der Änderungen eines unvollständig ausgeführten Programms
 - Rückgängigmachen der bereits ausgeführten Änderungen
- Nach Abschluss aller Änderungen eines Programms
 - Kompletieren der unvollständigen Änderungen bzw. Wiederholen verlorengegangener Änderungen

Voraussetzungen

- Geeignete Sicherungs- und Protokollierungsmaßnahmen im laufenden Betrieb (Log)
- Protokolldatei

Pufferverwaltung